AlzheimerDataHub : collecte, fiabilisation et exploitation de données sur la maladie d'Alzheimer

Synthèse du projet final, module Architectures BD et collecte de données, ESEO 2026-2027 **Auteure :** Wiem Ben M'sahel, 08/11/2026 **Dépôt :** https://github.com/WiemBenMsahel/personal-data-collector

1. Problème, utilisateur, indicateurs et sources

Problème. Les données cliniques brutes sont rarement prêtes à l'emploi : valeurs impossibles, doublons, schéma qui change. Un chercheur ou data analyst en santé ne peut pas s'appuyer dessus sans contrôle.

Question centrale. Quels indicateurs cliniques (MMSE, tension, cholestérol, âge) distinguent les patients diagnostiqués Alzheimer des autres, dans un jeu de données fiabilisé ?

Utilisateur et décision. Un chercheur ou data analyst en santé qui doit choisir les indicateurs à étudier en priorité. Traitement ponctuel (batch à la demande), car la source est figée.

Indicateurs (KPI).

Cas d'usage	KPI
Comparer le MMSE selon le diagnostic	MMSE moyen par diagnostic
Cibler la population à étudier	Part de patients diagnostiqués par tranche d'âge
Décider si le jeu est exploitable	Taux de lignes rejetées

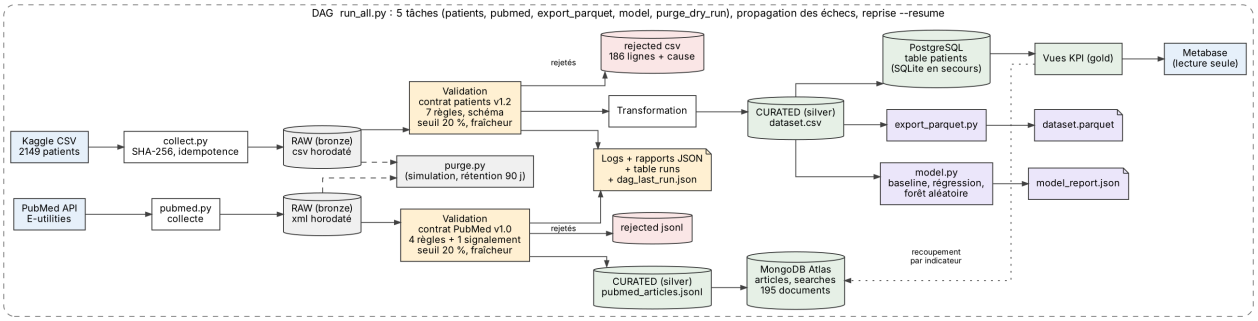
Sources.

Source	Rôle	Format	Licence / conditions	Accès
Kaggle, *Alzheimer's Disease Dataset* (R. El Kharoua)	Patients (principale)	CSV, 2149 lignes, 35 colonnes	CC BY 4.0, jeu synthétique	Téléchargement manuel, 03/11/2026
PubMed (API NCBI E-utilities)	Littérature (seconde)	XML, 195 articles	Politique d'usage du NCBI, métadonnées seulement	API publique, 06/11/2026
OASIS (imagerie)	Écartée	NIfTI / JPEG	Accord d'utilisation	Accès sur demande, volumes hors proportion

Il n'existe aucune clé commune entre les patients et les articles : le recoupement se fait **par indicateur**, pas par patient.

Conformité. Jeu patients synthétique, aucune donnée personnelle de tiers. Minimisation : 11 colonnes conservées sur 35 dans le curated, colonne `DoctorInCharge` (masquée) exclue. Pour PubMed, seules les métadonnées sont stockées. Aucun secret dans le dépôt (URI MongoDB dans `.env`, non versionné).

2. Pipeline et architecture



Chaîne patients. Collecte reproductible, zone raw horodatée avec hash SHA-256, validation pilotée par le contrat de données, rejets conservés, transformation, zone curated (CSV), base PostgreSQL (SQLite en secours) par UPSERT, vues SQL d'indicateurs, tableau de bord Metabase. Un modèle de classification et un export Parquet lisent la couche curated.

Chaîne PubMed. Recherche par indicateur (requêtes définies dans un contrat), raw XML horodaté, validation, curated JSONL, MongoDB Atlas (UPSERT sur `pmid`).

Grain et clés. Une ligne = un patient (clé `patient_id`) ; un document = un article (clé `pmid`).

Couche	Équivalent dans le projet
Bronze (raw)	`data/raw/` : copies non modifiées, rejouables
Silver (curated)	`dataset.csv`, table `patients`, `pubmed_articles.jsonl`, collection `articles`
Gold (mart)	Vues SQL `v_kpi_by_diagnosis` et `v_kpi_by_age_group`

Contrats de données. `config/data_contract.yaml` (patients, version 1.2) et `config/pubmed_contract.yaml` (PubMed, version 1.0) sont les sources de vérité : colonnes, règles de qualité, seuils de rejet (20 %), fraîcheur, rétention. Le code les lit ; des tests prouvent que modifier un contrat change le comportement.

Orchestration. Un DAG minimal en Python (`src/run_all.py`, bibliothèque standard) enchaîne 5 tâches : `patients` et `pubmed` (indépendantes), puis `export_parquet`, `model` et `purge_dry_run`. Une tâche ne démarre que si ses dépendances ont réussi ; en cas d'échec, ses descendantes sont marquées `UPSTREAM_FAILED` et les tâches indépendantes continuent. L'option `--resume` rejoue seulement ce qui n'avait pas réussi. Airflow n'est pas justifié : une machine, 5 tâches, aucune planification. Docker Compose fournit PostgreSQL et Metabase.

3. Qualité, incidents et observabilité

Règles de qualité. Patients : 7 règles (complétude, validité, cohérence, unicité), dont `bp_coherent` (tension diastolique inférieure à la systolique) qui a rejeté 186 lignes. Articles : 4 règles de rejet et 1 signalement. Les lignes rejetées sont conservées avec la cause (`reject_reason`), jamais supprimées en silence.

Contrôles au niveau du fichier ou du lot. Fichier vide, schéma (colonne manquante), seuil de rejet défini dans chaque contrat (publication bloquée au-delà de 20 %), fraîcheur (patients : avertissement au-delà de 30 jours ; PubMed : avertissement si l'article le plus récent a plus d'un an).

Incidents testés.

Incident	Détection	Résultat
Colonne manquante	contrôle du schéma	FAIL, code 1
Fichier vide	contrôle du schéma	FAIL, code 1
100 % de lignes invalides	seuil de rejet	FAIL, publication bloquée
Source introuvable	collecte	FAIL, code 1
100 % d'articles invalides (PubMed)	seuil de rejet PubMed	FAIL ; raw et rejets conservés ; curated non écrit
Panne de la source patients pendant le DAG	code de sortie de la tâche	`patients` en échec, 3 tâches `UPSTREAM_FAILED`, `pubmed` réussit ; reprise avec `--resume`
MongoDB injoignable (incident réel, 06/11)	erreur DNS	FAIL ; raw et curated conservés ; reprise après correction
Source trop ancienne (simulée, 45 jours)	fraîcheur	avertissement, statut PASS_WITH_WARNINGS

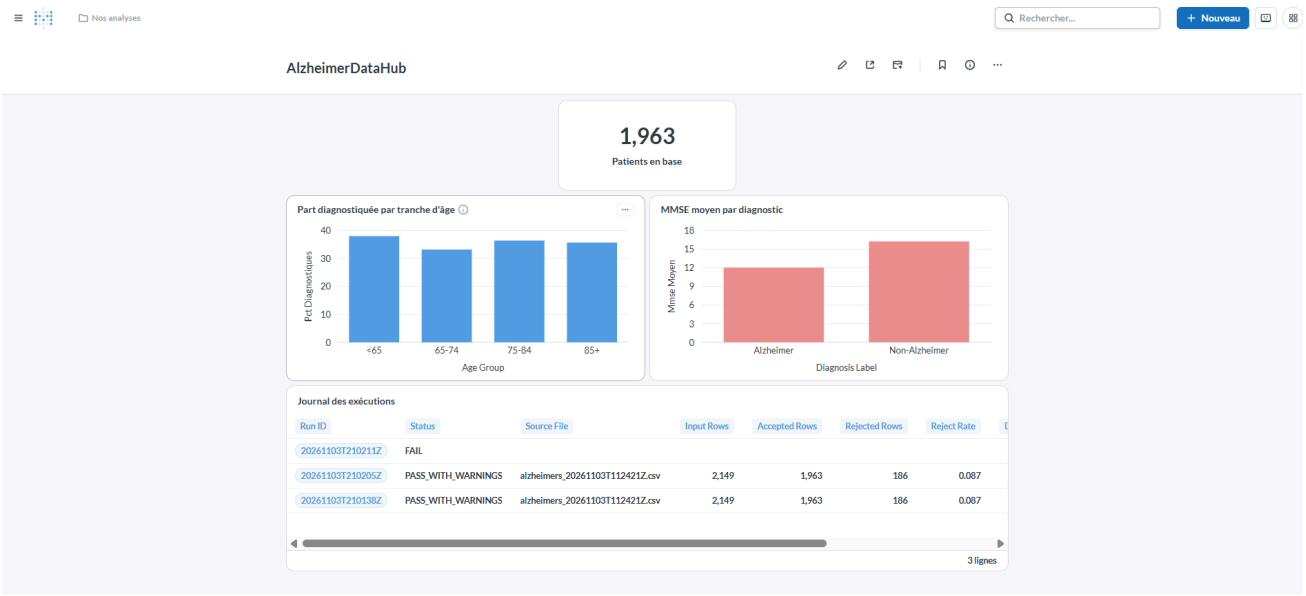
Dans les cas bloquants, le curated n'est pas modifié (hash SHA-256 identique avant et après) et, pour les patients, l'échec est inscrit dans la table `runs`. Reprise : relancer le pipeline sur le fichier valide ou `run_all.py --resume`.

Observabilité. Chaque exécution reçoit un `run_id` présent dans les logs, dans un rapport JSON (`reports/runs/`) et, pour les patients, dans la table `runs`. Le rapport contient volumes, taux de rejet, échecs par règle, âge de la source, fraîcheur, statut et durée. Le DAG conserve l'état de chaque tâche (`reports/dag_last_run.json`, preuve de panne dans `reports/dag_demo_failure.json`).

Idempotence. Relancer le pipeline ne duplique rien : 1963 patients en base après plusieurs exécutions, 195 articles dans MongoDB après plusieurs exécutions.

Tests et reproductibilité. 30 tests automatisés (règles de qualité, contrat, incidents, rétention, PubMed, modèle, DAG, export Parquet). Rejeu sur un clone propre du dépôt le 07/11/2026 : pipeline, 30 tests, seconde source (sans MongoDB) et modèle fonctionnent en suivant le README.

4. Résultat



Qualité de la source. 2149 lignes reçues, 1963 acceptées, 186 rejetées (8,7 %), toutes par la règle de cohérence de la tension.

Diagnostic	Patients	MMSE moyen	Tension systolique	Cholestérol total	Âge moyen
Alzheimer	694	12,0	137,1	225,7	74,9
Non-Alzheimer	1269	16,2	137,9	224,8	74,9

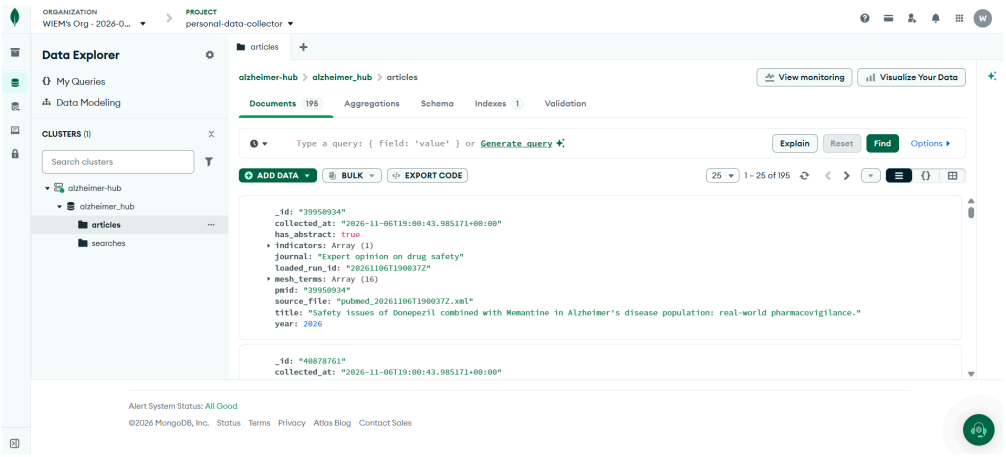
Tranche d'âge	Patients	Part diagnostiquée
< 65	314	37,9 %
65-74	658	33,1 %
75-84	615	36,3 %
85+	376	35,6 %

Lecture. Sur ce jeu, le MMSE est l'indicateur qui diffère le plus entre les deux groupes (12,0 contre 16,2). La tension, le cholestérol et l'âge moyen sont quasiment identiques, et la part de patients diagnostiqués varie peu selon la tranche d'âge (33 % à 38 %). Le jeu étant synthétique, ces résultats illustrent le pipeline et ne constituent pas des conclusions médicales.

Littérature (PubMed, 07/11/2026).

Indicateur	Articles PubMed (total)	Articles stockés
MMSE	6834	50
Tension artérielle	1328	50
Cholestérol	2303	50
Âge	5209	50

195 articles distincts sont stockés (5 articles correspondent à deux indicateurs). Le volume d'articles indique l'intérêt de la recherche pour chaque indicateur ; ce n'est pas une preuve de lien avec nos données.



Usage de la couche silver : modèle de classification. Pour vérifier quels indicateurs portent un signal, deux modèles (régression logistique, forêt aléatoire) estiment le diagnostic à partir des 9 indicateurs cliniques du curated. Ils sont comparés à une baseline qui prédit toujours la classe majoritaire, évalués par validation croisée à 5 plis puis sur un jeu de test de 393 lignes. La graine est fixée (42), donc les chiffres sont reproductibles, et le rapport conserve le hash du curated lu.

Modèle	AUC (validation croisée)	AUC (test)	Rappel
Baseline majoritaire	0,500	0,500	0,00
Régression logistique	0,711	0,722	0,60
Forêt aléatoire	0,715	0,757	0,48

Le signal est réel mais modeste, et les deux modèles sont à égalité en validation croisée. L'accuracy est trompeuse (la baseline atteint 0,646 sans détecter aucun patient) : on retient l'AUC et le rappel. Par importance par permutation, le MMSE (baisse d'AUC de 0,16) et les plaintes de mémoire (0,11) portent presque tout le signal ; la tension, le cholestérol et l'âge n'apportent presque rien, ce qui confirme les KPI et ajoute les plaintes de mémoire comme indicateur à étudier. Le MMSE servant déjà à poser le diagnostic en pratique, son poids reflète surtout la génération des données. Données synthétiques : aucune valeur médicale.

Mon travail sur le modèle. J'ai comparé les modèles à une baseline, choisi les métriques adaptées au déséquilibre des classes, vérifié que la cible n'est pas dans les variables (`diagnosis_label` et `age_group` exclus) et contrôlé la reproductibilité (graine fixée, mêmes chiffres sur deux exécutions et sur le clone propre). Le modèle sert à tester quels indicateurs portent un signal, pas à prédire.

Consultation. Tableau de bord Metabase (http://localhost:3000, lecture des vues KPI et de la table `runs`), requêtes SQL sur les vues, tableau de bord Streamlit de secours, rapport du modèle (`reports/model_report.json`), export Parquet (`data/curated/dataset.parquet`).

5. Décisions, limites et perspectives

Décision d'architecture (ADR 001). Options comparées : fichiers seuls, PostgreSQL seul (articles en JSONB), PostgreSQL + MongoDB Atlas, MongoDB seul. Option retenue : PostgreSQL pour les patients (données tabulaires, schéma fixe, clé primaire, vues KPI) et MongoDB Atlas pour les articles (documents semi-structurés, clé `pmid`). Architecture batch, raw en fichiers, DAG minimal en Python plutôt qu'Airflow. Pour le modèle, des algorithmes simples et interprétables (scikit-learn) suffisent à une démonstration sur 1963 lignes.

Compromis assumés. Deux systèmes de stockage pour de petits volumes. PostgreSQL avec une colonne JSONB aurait suffi techniquement pour 195 articles ; MongoDB a été retenu sur la recommandation de l'enseignant, avec un rôle volontairement limité. Condition de réexamen : revenir à PostgreSQL seul si la littérature reste de quelques centaines d'articles sans besoin de recherche textuelle. Le DAG n'a ni interface ni planification ; condition de réexamen : passer à Airflow ou Prefect si les sources deviennent périodiques.

Choix écartés. API (aucun consommateur : Metabase et les vues SQL servent déjà d'interface), streaming (sources peu volatiles), images IRM (pas de lien patient-à-patient).

Gouvernance. Responsable : l'auteure. Rétention : raw et rapports 90 jours (purge simulée par défaut). Aucune donnée personnelle. Traçabilité : `source_file` et `loaded_run_id` conservés sur chaque ligne ou document, lignage décrit dans `docs/lineage.md`.

Limites.

- Jeu synthétique : pas de valeur médicale.
- Téléchargement Kaggle manuel.
- Le fichier des rejets conserve la ligne source complète (acceptable en synthétique, à filtrer sur des données réelles).
- PubMed : 50 articles récents par indicateur, requête simple, pas de revue systématique ; pas de clé commune avec les patients ; seuil de fraîcheur simple.
- MongoDB Atlas dépend d'un compte externe (mode dégradé : JSONL local) ; l'incident MongoDB n'est pas couvert par un test automatisé.
- Modèle : démonstration seulement (9 indicateurs, un seul découpage train/test, pas de réglage des hyperparamètres).
- Aucune alerte envoyée, pas de planification automatique.

Perspectives. Téléchargement par l'API Kaggle, exécution automatisée (GitHub Actions + tests), alertes en cas d'échec, test automatisé de l'incident MongoDB, réentraînement du modèle avec davantage d'indicateurs du jeu source, migration du DAG vers Airflow si une planification devient nécessaire, intégration d'images IRM avec stockage objet.

Usage d'outils d'IA. Claude (Anthropic) a assisté la structuration, des squelettes de code, la documentation et la relecture ; le code a été exécuté, testé et vérifié (voir la section 16 du README pour le détail et les parties retravaillées personnellement).